吴伟恒

wdz478149507@gmail.com

中国科学院信息工程研究所, 北京, 中国

教育与经历

新加坡管理大学 *2026年8月起 -*

David LO教授组(ACM Fellow, IEEE Fellow, ASE Fellow), Code LLM & LLM4Sec 方向, 博士

中国科学院大学 *2023年9月 - 至今*

中国科学院信息工程研究所, 网络空间安全, 硕士

阿里巴巴 *2025年11月 - 至今(至2026年1月)*

达摩院智多星, 实习生

深圳大学 *2019年9月 - 2023年6月*

深圳大学, 电子与信息工程学院, 学士

学术论文发表

[WWW '25] **Brewing Vodka: Distilling Pure Knowledge for Lightweight Threat Detection in Audit Logs [第一作者 - CCF A]**

- 将知识蒸馏引入审计日志溯源领域, 以平衡检测精度与成本;
- 实现了一个结合MLP和Personalized PageRank的轻量级学生模型, 用于高效异常检测;
- 使用图拉普拉斯正则化和GNN框架来蒸馏结构与特征知识;
- 达到了SOTA精度, 同时推理时间相比现有方法减少了1.4–5.2倍。

[TIFS '25] **SAURONEYES: Disentangling Voluminous Logs to Unveil Deep Threat Intentions [共同第一作者 - CCF A]**

- 设计了一个APT检测系统, 使用图解耦和多视图对比学习来分离攻击意图;
- 应用此方法解耦伪装行为、处理数据稀疏性并重建攻击;
- 在真实世界数据集上实现了99%的准确率和0.1%的误报率, 精度和鲁棒性优于SOTA方法。

[AAAI '26] **Sentient: Detecting APTs Via Capturing Indirect Dependencies and Behavioral Logic [第四作者 - CCF A]**

- 提出了结合预训练和意图分析的APT检测框架Sentient;
- 构建了基于Graph Transformer的预训练模块，有效捕获溯源图中的全局结构信息与间接依赖;
- 设计了意图分析模块(IAM)，创新性地应用双向Mamba2 (Bi-Mamba2) 模型学习行为间的逻辑关联，并构建去噪场景以消除环境噪声;
- 采用仅基于良性数据的训练策略，在三个数据集上的评估优秀性能。

[S & P '26 已投稿] **PROVX: Generating Counterfactual-Driven Attack Explanations for Provenance-Based Detection [第一作者 - CCF A]**

- 提出了PROVX, 为基于GNN的溯源图模型生成人类可理解的反事实解释;
- 将解释搜索表述为一个连续优化问题, 以确保稳定性和清晰性;

- 设计了一个闭环反馈框架, 利用解释来重新训练并增强模型的鲁棒性;
- 在DARPA数据集上取得了SOTA性能, 平均解释必要性为51.59%, 优于现有解释器。

[INFOCOM '26 已投稿] **M3NTC: Multitask Multimodal Network Traffic Classification with Pre-training Transformers [第四作者 - CCF A]**

- 提出 M³NTC, 一个新颖的多模态预训练 Transformer 框架 [cite: 267, 272], 旨在解决加密流量分类中对大规模标注数据的依赖问题;
- 创新地将网络流量映射为三种模态：文本（负载字节）、图像（协议结构）和音频（时间序列特征）;
- 设计了掩码图像建模(MIM)和掩码音频建模(MAM)两种自监督预训练任务, 使模型能从无标签数据中学习跨模态交互信息;
- 在四个公共数据集上, M³NTC 的平均准确率相比现存方法提升了11.5%。

[WWW '26 已投稿] **Adventures of ROBINSON: Escaping Data Silos for Federation-Driven APT Detection [第一作者 - CCF A]**

- 提出了一种使用同态加密的联邦学习架构, 在跨数据孤岛学习的同时确保隐私;
- 设计了一种带有自适应滤波和图记忆模块的胶囊GNN, 以捕获APT攻击链中的长程依赖.

[ICASSP '26 已投稿] **BTDA: A ROBUST FRAMEWORK FOR ENCRYPTED TRAFFIC CLASSIFICATION WITH BYTE-LEVEL TLS DATA AUGMENTATION [第五作者 - CCF B]**

- 提出 BTDA 框架, 旨在解决由不同系统和浏览器实现的 TLS 指纹差异（"TLS dialect problem"）导致的泛化难题;
- 引入一种协议指导的 TLS 数据增强引擎, 通过密码套件操纵、扩展重排序等方式模拟多样化的TLS握手实现;
- 采用自监督预训练范式, 结合流间对比学习(FCL)与流内掩码建模(MBM), 提取独立于客户端伪影的稳健流量表征;
- 实验证明, 该方法在三个数据集上的F1-score相比SOTA方法提升了3.8%。

[Usenix Sec'26 Round 2] **BACKTRACK: Bridging Gaps in Audit Logging for Reliable Provenance [第五作者 - CCF A]**

- 针对现有审计系统面临的上下文丢失、语义模糊及高负载下丢事件等挑战, 提出了BACKTRACK审计系统;
- 引入一个运行时上下文重构机制, 在用户空间维护内核资源状态的抽象, 并在必要时通过查询 `procfs` 按需恢复丢失的状态;
- 采用基于eBPF的catcher捕获与溯源相关的系统调用, 并设计了一个多线程并发的 dispatcher 以解决生产者-消费者瓶颈, 保证高吞吐量;
- 实验表明, BACKTRACK 能多捕获高达 41.7% 的关键桥接路径, 并将不可解析的日志比例降低 22.9%。

[ICASSP '26 已投稿] **ARKENSTONE: A SELF-AUGMENTING AND CONSISTENCY-GUIDED FRAMEWORK FOR SEMI-SUPERVISED APT DETECTION [第一作者 - CCF B]**

- 针对溯源图 APT 检测中高质量标注数据严重稀缺的问题, 提出了一个新颖的半监督学习框架 ARKENSTONE。

- 框架的核心是一种结合了一致性训练(Consistency Training)和可学习数据增强(Learnable Data Augmentation) 的策略;
- 创新地设计了一个可学习的数据增强模块, 该模块基于注意力网络(Attention Network)智能生成增强样本（而非随机增强）, 迫使模型学习系统行为的稳健表征;
- 采用交替训练策略, 结合GraphSAGE高效利用大量无标签审计日志, 缓解对人工标注的依赖;
- 实验证明, 仅用10%的标注数据, ARKENSTONE 的表现便可超越多数SOTA方法。

专业技能

- **英语水平**: CET-6
- **编程语言**: 精通 Python (PyTorch, scikit-learn, NumPy, Matplotlib), C语言。
- **机器学习与深度学习**: 熟悉图神经网络 (GNN); 图解释性; 异常检测算法; 对抗性鲁棒性机器学习。
- **网络安全**: 深入理解高级持续性威胁 (APT) 检测; 熟悉溯源图分析、系统审计日志处理、攻击链重建; 熟悉 MITRE ATT&CK 框架和威胁狩猎。
- **大语言模型**: 深入理解Transformer架构原理，熟练掌握模型微调（Fine-tuning）与提示工程；具备与企业合作构建垂直领域大模型评测基准（Benchmark）的完整经验；目前专注于CodeLLM及LLM Agent在软件工程等方向（如代码生成、异常检测）中的应用研究，并持续探索LLM自身安全性与前沿任务。

关于我

- **逻辑与推理:** 作为一名侦探小说爱好者, 我热衷于分析复杂的线索, 构建逻辑链, 并最终揭开谜底。
- **分析与表达:** 作为一名业余影评人, 我喜欢解构电影叙事和艺术技巧, 并通过撰写评论来磨练我的批判性思维和书面沟通能力。
- **探索与好奇心:** 凭借对天文学的浓厚兴趣, 我喜欢观察夜空和学习宇宙知识, 这激发了我持久的好奇心和对未知的探索欲。